



Received 00th January 20xx  
Accepted 00th February 20xx  
Published 00th March 20xx

Open Access

DOI: 10.35472/x0xx0000

## Analisis Data Cuaca NYC Central Park Tahun 2016 dengan Model Stasioner AR(p), MA(q), dan ARMA(p,q)

Meinisa<sup>a</sup>, Maria Gresia Hutabarat<sup>b</sup>, Josua Alfa Viando Panggabean<sup>c</sup>, Putri Intan Kirani<sup>d</sup>, Rizky Adrian Bennovry<sup>e</sup>, Ibnu Farhan Al-Ghifari<sup>f</sup>

<sup>a</sup> 121450076

<sup>b</sup> 121450057

<sup>c</sup> 121450061

<sup>d</sup> 121450055

<sup>e</sup> 121450073

<sup>f</sup> 121450121

\* Corresponding E-mail: [journal@itera.ac.id](mailto:journal@itera.ac.id)

**Abstract:** This study analyzes daily weather data from Central Park, New York, in 2016. The analysis was conducted using AR(p), MA(q), and ARMA(p,q) stationary models. The dataset contains variables such as maximum temperature, minimum temperature, average temperature, rainfall, snowfall, and snow depth. To ensure the stability of the data, the Augmented Dickey-Fuller (ADF) test was conducted, and differencing was used where necessary. ARMA was chosen for its ability to combine autoregressive (AR) and moving average (MA) components, which allows the model to capture both short-term fluctuations and long-term trends in the time series. After evaluating several models, ARIMA (112) was identified as the most suitable model based on the AIC and BIC values. The model correctly anticipates seasonal temperature patterns, including an increase during summer and a decrease during winter. This research adds to the understanding of weather variability in urban areas and is useful for infrastructure planning and risk management. The insights gained from this analysis can help in preparation for extreme weather, supporting policy makers and urban planners to reduce disruptions due to sudden temperature changes.

**Keywords:** ARMA model, time series analysis, temperature forecasting, stationarity, Central Park weather

**Abstrak:** Penelitian ini menganalisis data cuaca harian dari Central Park, New York, pada tahun 2016. Analisis dilakukan menggunakan model stasioner AR (p), MA (q), dan ARMA (pq). Dataset ini berisi variabel seperti suhu maksimum, suhu minimum, suhu rata-rata, curah hujan, curah salju, dan kedalaman salju. Untuk memastikan kestabilan data, dilakukan uji Augmented Dickey-Fuller (ADF), dan perbedaan digunakan jika diperlukan. ARMA dipilih karena kemampuannya menggabungkan komponen autoregressive (AR) dan moving average (MA), yang memungkinkan model ini menangkap fluktuasi jangka pendek dan tren jangka panjang dalam deret waktu. Setelah mengevaluasi beberapa model, ARIMA (112) diidentifikasi sebagai model yang paling sesuai berdasarkan nilai AIC dan BIC. Model ini dengan tepat mengantisipasi pola suhu secara musiman, termasuk kenaikan selama musim panas dan penurunan selama musim dingin. Penelitian ini menambah pemahaman tentang variabilitas cuaca di perkotaan dan berguna untuk perencanaan infrastruktur serta manajemen risiko. Wawasan yang diperoleh dari analisis ini dapat membantu dalam persiapan menghadapi cuaca ekstrem, mendukung pembuat kebijakan dan perencana kota mengurangi gangguan akibat perubahan suhu tiba-tiba.

**Kata Kunci :** model ARMA, analisis deret waktu, peramalan suhu, stasioneritas, cuaca Central Park



## Pendahuluan

Dalam dunia transportasi, cuaca merupakan salah satu faktor faktor penting yang secara langsung mempengaruhi kondisi lalu lintas dan waktu tempuh sebuah kendaraan. Cuaca yang buruk dapat menyebabkan peningkatan volume lalu lintas serta penurunan kualitas jalan, yang pada akhirnya akan meningkatkan volume lalu lintas serta penurunan kualitas jalan. Hujan lebat, suhu ekstrim dan turunnya salju adalah faktor-faktor penyebab cuaca mempengaruhi kondisi sebuah jalan dan lalu lintas. Hujan lebat dapat memberikan kurangnya intensitas cahaya dan jarak pandang suatu kendaraan. Turunnya salju dapat memberikan dampak terhadap kondisi sebuah jalan seperti adanya timbunan salju di jalan yang menyebabkan jalan tidak dapat terlihat lagi oleh kendaraan.

Untuk memitigasi dampak buruk cuaca terhadap lalu lintas, prediksi cuaca yang akurat menjadi sangat krusial dalam perencanaan transportasi dan pengelolaan lalu lintas. Dengan menggunakan data cuaca historis, kita dapat mengidentifikasi pola cuaca yang mempengaruhi lalu lintas dan menggunakan pola tersebut untuk memprediksi kondisi cuaca di masa mendatang. Salah satu metode yang efektif dalam analisis deret waktu adalah model ARMA (*Autoregressive Moving Average*) yang merupakan metode yang efektif dalam peramalan menggunakan data historis. Melalui model ARMA ini, kita dapat menganalisis berbagai variabel pada data seperti suhu, curah hujan, dan kedalaman salju yang menghasilkan prediksi atau peramalan yang akan berguna untuk perencanaan lalu lintas dan infrastruktur

Selain itu, peramalan cuaca berbasis metode ARMA juga dapat membantu dalam manajemen sumber daya transportasi. Misalnya dengan prediksi hujan dan salju yang akurat, dapat memitigasi jalan dengan lebih siap dalam membersihkan jalan dari salju atau genangan air sehingga memastikan arus lalu lintas lancar. Dalam dunia yang semakin bergantung pada prediksi dan analitik diharapkan peramalan cuaca yang akurat akan berperan penting dalam memastikan kelancaran arus lalu lintas dan mengurangi dampak cuaca buruk pada mobilitas masyarakat.

## Metode

### 1. Deskripsi Dataset

Data yang digunakan dalam penelitian ini diambil dari dataset suhu maksimum harian di Central Park, New York, selama tahun 2016. Dataset ini diimpor menggunakan library readxl, dan hanya dua kolom yang diambil, yaitu tanggal dan suhu maksimum.

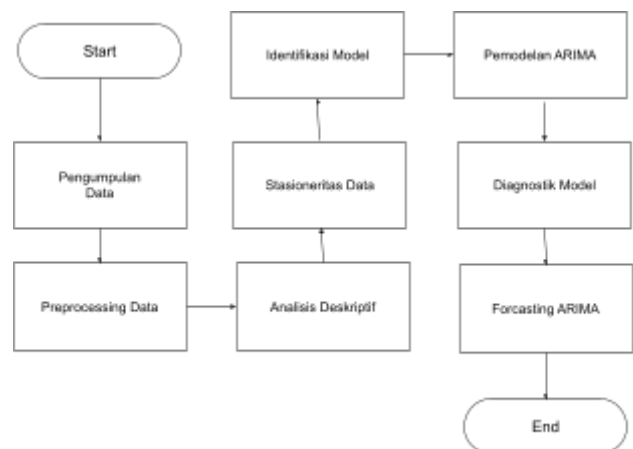
**Tabel 1.** Sampel Dataset

Date	Max Temp	Min Temp	Average Temp	Precipitation	Snow Fall
01/01/2016	42	34	38.0	0.00	0.0
02/01/2016	40	32	36.0	0.00	0.0
03/01/2016	45	35	25.0	0.00	0.0
...	...	...	...	...	...
31/12/2016	44	31	37.5	0	0

Dataset cuaca yang digunakan mencakup data harian dari Januari hingga Juli 2016. Di dalamnya terdapat beberapa informasi penting seperti suhu maksimum, suhu minimum, dan suhu rata-rata setiap harinya. Selain itu, dataset ini juga mencatat jumlah curah hujan yang turun setiap hari, apakah terjadi salju, dan seberapa tebal salju yang menutupi tanah. Namun hanya dua kolom yang diambil, yaitu tanggal dan suhu maksimum. Berikut adalah penjelasan setiap variabel tersebut:

1. *Date* (Tanggal): Variabel ini mencatat tanggal spesifik untuk setiap entri cuaca harian.
2. *Maximum Temperature* (Suhu Maksimum): Variabel ini merekam suhu tertinggi yang tercatat pada suatu hari.

### 2. Diagram Alir Penelitian



**Gambar 1.** Diagram Alir Penelitian

### 3. Metode ARMA (*Autoregressive Moving Average*)

Metode ARMA (*Autoregressive Moving Average*) adalah salah satu pendekatan dalam analisis deret waktu yang menggabungkan dua komponen utama autoregressive (AR) dan moving average (MA). Metode ini sangat efektif untuk memodelkan data deret waktu yang bersifat stasioner, yaitu data yang nilai rata-rata, varians, dan autokovariansinya tetap konstan sepanjang waktu.

Pada dasarnya, model AR(p) memperkirakan nilai masa depan berdasarkan nilai-nilai masa lalu dari data itu sendiri. Misalnya, jika ada tren atau pola musiman di data, model AR dapat mendeteksinya. Sementara itu, model MA(q) memperhitungkan error atau gangguan acak dari waktu-waktu sebelumnya. Kombinasi kedua pendekatan ini memungkinkan model ARMA untuk menangkap pola jangka pendek (seperti fluktuasi harian atau bulanan) dan jangka panjang (seperti tren tahunan). Pada penelitian yang dilakukan Sánchez-Lugo Dkk(2021), model ARMA mampu menangkap variabilitas suhu jangka pendek dan panjang yang signifikan dalam data meteorologi[1]. Dengan penerapan metodologi ini dapat diperoleh pemahaman yang lebih mendalam mengenai fluktuasi suhu terkait dengan perubahan iklim[2].

#### 1. Komponen ARMA

##### • Autoregressive (AR)

Komponen AR dalam model ARMA mengasumsikan bahwa nilai saat ini dari variabel bergantung secara linear pada nilai sebelumnya, yaitu nilai lag dari variabel yang sama. Ini dapat digambarkan sebagai proses di mana variabel masa lalu mempengaruhi variabel saat ini melalui koefisien *autoregressive*.

- Order AR (p), Order dari komponen AR ditentukan oleh jumlah lag yang digunakan. Misalnya, model AR(1) menggunakan satu nilai lag, AR(2) menggunakan dua nilai lag, dan seterusnya.
- Komponen AR dari model ARMA (p) dapat dinyatakan sebagai:

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \epsilon_t$$

Dimana  $y_t$  adalah nilai observasi pada waktu  $t$ ,  $\phi_1, \phi_2, \dots, \phi_p$  adalah koefisien *autoregressive*, dan  $\epsilon_t$  adalah error pada waktu  $t$ .

- Koefisien autoregressive  $\phi$  merepresentasikan pengaruh observasi masa lalu terhadap nilai saat ini. Jika nilai  $\phi_1$  mendekati 1, maka ada ketergantungan kuat antara observasi sekarang dan sebelumnya.

##### • Moving Average (MA)

Komponen MA menangani hubungan linear antara nilai sekarang dan error masa lalu. Error yang dimaksud di sini adalah deviasi antara nilai yang sebenarnya dan nilai yang diprediksi oleh model di masa lalu.

Komponen MA menangani hubungan linear antara nilai sekarang dan error masa lalu. Error yang dimaksud di sini adalah deviasi antara nilai yang sebenarnya dan nilai yang diprediksi oleh model di masa lalu.

- Order MA (q), Komponen MA pada model ARMA melibatkan order q, yang mengacu pada jumlah error masa lalu yang digunakan untuk memperkirakan nilai saat ini.
- Komponen MA dari model ARMA (q) dinyatakan sebagai:

$$y_t = \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \dots + \theta_q \epsilon_{t-q} + \epsilon_t$$

Dimana  $\theta_1, \theta_2, \dots, \theta_q$  adalah koefisien *moving average*, dan  $\epsilon_t$  adalah error sekarang.

- Koefisien  $\theta$  dalam komponen MA menunjukkan kontribusi dari error masa lalu dalam mempengaruhi nilai saat ini. Besar kecilnya error masa lalu berperan penting dalam prediksi nilai berikutnya.

#### 2. Kombinasi ARMA

Kedua komponen AR dan MA digabungkan dalam model ARMA (p, q) untuk membentuk persamaan:

$$y_t = \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q} + \epsilon_t$$

Keterangan :

- $y_t$  : nilai observasi pada waktu t
- $\phi_1.. \phi_p$  : koefisien Autoregressive
- $\theta_1.. \theta_q$  : koefisien moving average
- $\epsilon_t$  : error pada waktu t
- p : urutan AR
- q : urutan MA.

Dengan kombinasi ini, ARMA mampu menangkap dinamika data time series yang tidak hanya dipengaruhi oleh observasi masa lalu tetapi juga oleh error atau ketidakpastian masa lalu.

#### 4. Tahapan Utama Pemodelan ARMA

##### 1. Identifikasi Order Model ARMA

Langkah pertama dalam membangun model ARMA adalah menentukan nilai order AR (p) dan MA (q), yang menunjukkan jumlah lag dari variabel autoregressive (AR) dan moving average (MA). Proses ini bisa dilakukan dengan memeriksa dua fungsi penting:

- *Autocorrelation Function* (ACF): ACF membantu mengidentifikasi komponen MA (q) dalam model dengan melihat hubungan antara nilai saat ini dengan lag dari error masa lalu. Jika grafik ACF menunjukkan penurunan yang cepat atau berhenti setelah beberapa lag, ini adalah indikasi dari komponen moving average dalam model.
- *Partial Autocorrelation Function* (PACF): PACF digunakan untuk menentukan komponen AR (p). Grafik PACF memperlihatkan seberapa besar pengaruh nilai masa lalu terhadap nilai saat ini, tanpa mempertimbangkan pengaruh nilai di antara lag. Jika PACF menurun tajam setelah beberapa lag, ini mengindikasikan nilai order AR yang sesuai.

ACF dan PACF sangat penting dalam menentukan urutan komponen AR dan MA yang benar, memfasilitasi spesifikasi model ARMA yang akurat[3] dengan melihat pola dalam grafik ACF dan PACF, kita bisa menentukan nilai yang tepat untuk p dan q secara empiris. Sebagai contoh, jika PACF menurun tajam setelah lag ke-2 dan ACF menunjukkan penurunan setelah lag ke-1, model ARMA dengan AR(2) dan MA(1) mungkin cocok.

##### 2. Uji Stasioneritas Data

Sebelum membangun model ARMA, data time series yang digunakan harus stasioner. Stasioneritas berarti bahwa rata-rata, varians, dan kovarians data tetap konstan sepanjang waktu. Jika data tidak stasioner, maka model ARMA mungkin tidak memberikan hasil yang akurat. Uji stasioneritas biasanya dilakukan dengan menggunakan metode berikut:

- *Augmented Dickey-Fuller (ADF) Test*: Uji ini memeriksa apakah ada unit root dalam data, yang mengindikasikan ketidakstasioneran. Jika nilai p dari hasil uji lebih kecil dari 0,05, maka data dianggap stasioner.
- *KPSS Test*: Sebaliknya, KPSS test menguji hipotesis bahwa data adalah stasioner. Jika hasil uji menunjukkan nilai p yang lebih besar dari 0,05, maka data dianggap stasioner.

Memastikan stasioneritas menggunakan uji ADF dan KPSS sangat penting untuk pemodelan ARMA[], jika hasil uji menunjukkan bahwa data tidak stasioner, maka diperlukan transformasi seperti *differencing* untuk menghilangkan tren atau pola musiman dan membuat data menjadi stasioner.

##### 3. Estimasi Parameter Model

Setelah order model ARMA ditentukan, parameter dari komponen AR dan MA harus diestimasi. Dua

metode utama yang digunakan untuk estimasi parameter adalah:

- Maximum Likelihood Estimation (MLE) merupakan metode yang bertujuan untuk menemukan nilai parameter yang memaksimalkan kemungkinan bahwa data yang diamati dihasilkan oleh model ARMA.
- Metode Least Square, metode ini mencoba untuk meminimalkan jumlah kuadrat dari selisih antara nilai yang diamati dan yang diprediksi oleh model. Metode ini sering digunakan karena lebih sederhana daripada MLE.

#### 4. Evaluasi dan Validasi Model


Setelah model ARMA dibangun, langkah terakhir adalah mengevaluasi apakah model tersebut sesuai dengan data. Dua aspek utama dalam evaluasi model adalah:

- Kriteria Seleksi Model (AIC dan BIC, Akaike Information Criterion (AIC) dan Bayesian Information Criterion (BIC) adalah dua kriteria yang digunakan untuk memilih model yang terbaik. Keduanya mempertimbangkan kecocokan model terhadap data, serta memberikan penalti pada model yang terlalu kompleks. Model dengan nilai AIC atau BIC yang lebih rendah dianggap lebih baik.
- Analisis Residual, Residual adalah perbedaan antara nilai yang diprediksi oleh model dan nilai yang sebenarnya diamati. Residual yang baik harus berupa white noise, artinya tidak memiliki pola yang signifikan atau korelasi antar lag. Jika residual menunjukkan pola tertentu, itu artinya model mungkin masih belum menangkap seluruh struktur dalam data[3].

Grafik ACF residual atau uji seperti Ljung-Box Test dapat digunakan untuk mengevaluasi apakah residual sudah bersifat white noise.


## Hasil dan Pembahasan

Boxplot yang ditunjukkan Gambar 2 menggambarkan distribusi suhu cuaca maksimal yang terjadi di Kota New York selama Tahun 2016.



**Gambar 2.** Boxplot Suhu Cuaca Kota New York Tahun 2016

Nilai suhu sebagian besar berkisar antara 60 hingga 80 dengan median berada di sekitar 65, menunjukkan bahwa separuh dari nilai suhu lebih rendah dan separuh lainnya lebih tinggi dari titik tersebut. Rentang nilai interquartile (IQR), yang mencakup 50% nilai tengah data, berada antara 60 hingga 80. Nilai minimum dan maksimum berkisar antara 20 hingga 85, tanpa adanya nilai yang dianggap outlier. Median yang tidak berada di tengah kotak menunjukkan bahwa distribusi data sedikit condong ke kanan, mengindikasikan adanya nilai suhu yang lebih tinggi yang menarik distribusi.



**Gambar 3.** Plot Time Series Cuaca Kota New York Tahun 2016

Plot deret waktu suhu cuaca di Kota New York sepanjang tahun 2016 yang terlihat pada Gambar 3, menggambarkan fluktuasi suhu dari Januari hingga Desember, dengan nilai suhu yang diukur dalam derajat Celcius. Periode musim dingin dan musim semi ditandai dengan latar berwarna biru, sementara musim panas dan musim gugur ditandai dengan latar berwarna merah muda. Suhu terlihat meningkat secara bertahap dari awal tahun, mencapai puncak di musim panas (sekitar pertengahan tahun), dan kemudian menurun lagi menjelang akhir tahun saat memasuki musim dingin. Pola ini mencerminkan karakteristik iklim musiman di New York, di mana suhu lebih rendah pada musim dingin dan meningkat signifikan selama musim panas. Variabilitas suhu juga terlihat lebih tinggi pada musim panas, dengan fluktuasi suhu yang lebih sering terjadi dibandingkan musim lainnya.

**Tabel 2** Uji Stasioner dengan Uji ADF Tanpa *Differencing*

Nilai Uji ADF	Lag Order	P-Value
-0.61924	0	0.457


Uji Augmented Dickey-Fuller (ADF) merupakan salah satu metode yang digunakan untuk menguji stasioneritas suatu data dalam analisis deret waktu. Dalam konteks pengujian yang dilakukan, nilai uji ADF diperoleh sebesar -0.61924. Nilai negatif tersebut mencerminkan bahwa data memiliki kecenderungan mendekati sifat stasioner, namun hal ini belum cukup untuk memastikan bahwa data tersebut sepenuhnya stasioner. Pada pengujian ini, lag order yang digunakan adalah 0, yang berarti tidak ada lag tambahan yang digunakan dalam model. Hal ini menunjukkan bahwa pengaruh autoregresif dalam data tidak diperhitungkan dalam pengujian ini. P-value yang diperoleh dari hasil uji adalah 0.457, yang lebih besar dari tingkat signifikansi 0.05. Dalam konteks uji ADF, hipotesis nol menyatakan bahwa data memiliki akar unit atau bersifat nonstasioner. Dengan demikian, keputusan dari hasil uji ini adalah untuk tidak menolak  $H_0$ , yang berarti data tersebut dianggap nonstasioner.

**Tabel 3** Uji Stasioner dengan Uji ADF Dengan *Differencing* 1 kali

Nilai Uji ADF	Lag Order	P-Value
-17.69	0	0.01

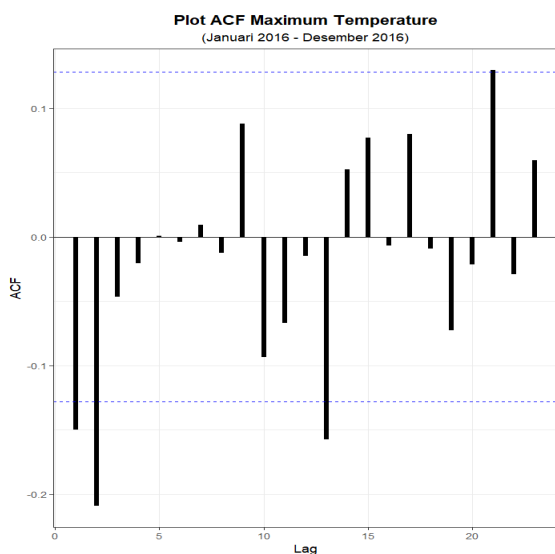
Hasil pengujian stasioner menggunakan Uji ADF dengan *differencing* Sebanyak 1 kali, ditunjukkan oleh gambar pada tabel 3. Nilai uji ADF diperoleh nilai sebesar -17.69 dari yang sebelumnya -0.61924, nilai negatif pada hasil pengujian ini menunjukkan bahwa data lebih mendekati sifat stasioner. Perlakuan dengan menambah *differencing* 1 kali agar data yang diperoleh nantinya adalah data stasioner. lag order 0 mengindikasikan bahwa tidak terdapat penambahan pada uji ADF nya, dan p-value nya adalah 0.01 dari yang sebelumnya 0.457. 0.01 lebih kecil dari 0.05 maka keputusan yang diperoleh adalah menerima  $H_0$ . berdasarkan hasil diatas dapat ditarik keputusan bahwa data tersebut sudah menjadi data stasioner setelah dilakukan uji stasioner dengan menggunakan uji ADF sebanyak 1 kali.






**Gambar 4.** Plot Time Series Cuaca Kota New York Tahun 2016 setelah differencing pertama

Pada Gambar 4, menampilkan plot ACF dari data temperatur maksimum terhadap waktu sebanyak 1 kali ( $d=1$ ). Gambar diatas menunjukkan temperatur maksimum yang cenderung meningkat dari waktu ke waktu walaupun fluktuasi yang terjadi cukup signifikan. Setelah dilakukannya *differencing* sebanyak satu kali, akan menghilangkan tren, fluktuasi lebih teratur dan data sebelumnya menjadi data stasioner.



**Gambar 5.** Plot ACF Maksimum Temperature

Gambar 5 menunjukkan plot ACF yang telah mengalami *differencing* sebanyak 1 kali. Data ini merupakan plot data ACF dari Januari 2016 hingga Desember 2016. diperoleh hasil bahwa nilai autokorelasi pada beberapa lag signifikan, namun beberapa lagi mendekati nol. Hasil dari pergerakan garis dalam grafik pada gambar 5 menunjukkan bahwa *differencing* telah mengurangi autokorelasi pada lag yang lebih tinggi apabila dibandingkan dengan sebelumnya. pada lag ke-0, ke-1, dan ke-2 memiliki nilai autokorelasi yang besar (signifikan). terdapat autokorelasi di lag ke-13, yang mengindikasikan adanya suatu pola siklus berulang. sementara setelah lag ke-2, nilai ACF nya mendekati nol, hal ini berarti data di lag yang lebih tinggi tidak lagi memiliki korelasi yang signifikan.



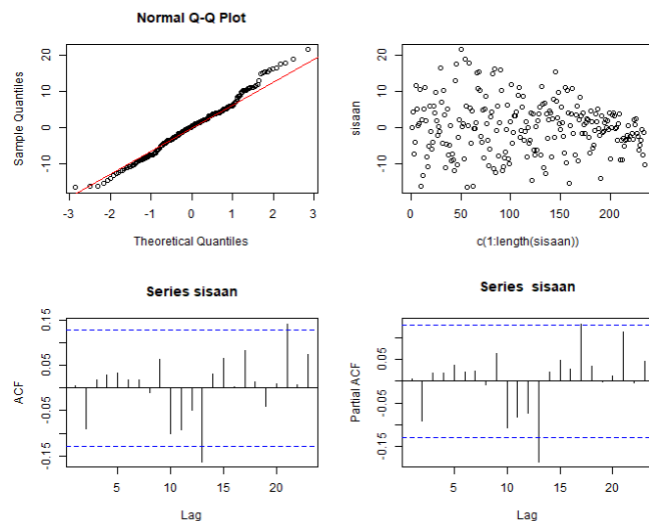
**Gambar 6.** Plot PACF Maksimum Temperature

Hasil yang ditunjukkan pada gambar 6, Data ini merupakan plot data PACF dari Januari 2016 hingga Desember 2016. Diperoleh hasil bahwa nilai autokorelasi pada beberapa lag signifikan, namun beberapa lagi mendekati nol. Plot Partial Autocorrelation Function (PACF) merupakan grafik yang menunjukkan korelasi parsial antara nilai dalam deret waktu dan nilai lag nya. pada setiap lag ke-1 pada PACF maupun ACF akan sama, hal ini disebabkan tidak ditemukannya nilai antara nilai saat ini dengan lag pertama. apabila dianalisis pada gambar 6, garis hitam lebih banyak mengarah ke bawah melewati garis pembatas.

**Tabel 4** Nilai AIC dan BIC dari Berbagai Model ARMA


ARMA (p,q)	AIC	BIC
ARMA (0,1)	1636.857	1643.759
ARMA (0,2)	1628.988	1639.341
ARMA (1,0)	1766.157	1773.059
ARMA ( 1,1)	1633.834	1644.187
ARMA ( 1,2)	1604.122	1617.926
ARMA (2,0)	1724.340	1734.693
ARMA (2,1)	1622.868	1636.672
ARMA (2,2)	1605.592	1622.847

Berdasarkan tabel 4, model ARMA (1,2) memiliki nilai AIC dan BIC yang paling rendah yakni untuk AIC sebesar 1604.122 Sedangkan BIC adalah 1617.926. Arima (1,1,2) dipilih karena memiliki nilai paling rendah dibandingkan dengan model lainnya hal ini menunjukkan kesetaraan yang baik diantara fit dan kompleksitas masing masing model.

**Gambar 7.** Hasil Uji Diagnostik

Berdasarkan Gambar 7 menunjukkan hasil uji diagnostik suhu maksimum harian di Central Park, New York, selama tahun 2016. Plot normal q-q plot pada gambar

memberikan gambaran kuartil residual terhadap kuartil teoritis, titik titik dalam gambar tersebut mengikuti garis merah, hal ini berarti residual berdistribusi dengan normal. Gambar kedua merupakan plot residual dengan indeks, adapun fungsi dari plot ini adalah untuk memastikan variansi pada suhu maksimum harian di Central Park, New York selama tahun 2016 konstan. Titik titik tersebar secara acak dan bebas, hal ini menunjukkan bahwa data memiliki tersebar dengan konstan. Gambar selanjutnya adalah gambar pada plot fungsi autokorelasi (ACF), pada gambar titik pada garis cenderung mendekati nol. Terakhir, ditunjukkan oleh gambar plot fungsi autokorelasi parsial (PACF), untuk mengukur relasi yang terjadi diantara kedua residual dengan memperkirakan waktu jedaanya. Berdasarkan plot PACF, grafik menunjukkan tidak adanya autokorelasi yang signifikan.

**Gambar 8.** Plot Forecast Berdasarkan ARMA (2,1) Dengan Menggunakan Drift

Pada gambar 8 menunjukkan plot forecast ARMA(2,1) dengan menggunakan drift mendeskripsikan prediksi di masa yang akan datang menggunakan data time series berdasarkan model. garis hitam pada gambar menunjukkan kenaikan yang cukup signifikan di setiap skala rentang waktu yang diberikan. garis yang memiliki kecenderungan mengalami kenaikan tersebut adalah sebagai nilai prediksi sementara garis forecast akan mengikuti kenaikan pada tren tersebut. Selang kepercayaan yang digunakan adalah sebesar 95%. Interval prediksi pada gambar 6 yang diberikan oleh plot diatas menunjukan ketidakpastian yang semakin besar semakin jauh ke masa yang akan datang, dan drift disini berfungsi untuk membantu forecast bergerak mengikuti trend (bergerak ke atas atau ke bawah).



**Tabel 5** Perbandingan Nilai Aktual dan Nilai Hasil Forecast  
Dari Data Testing Menggunakan ARMA (2,1)

Data	Nilai Aktual	Nilai Forecast
1	82	84.679
2	88	88.791
3	86	91.329
4	90	92.905
5	89	93.920

Berdasarkan Tabel 5, diperoleh hasil bahwa pemodelan dengan menggunakan ARMA (2,1) bervariasi dalam melakukan akurasi prediksi khususnya untuk data testing. Nilai perbandingan antara nilai aktual dan nilai peramalan (*forecasting*) sangat bervariasi tetapi tidak jauh berbeda, jika menggunakan metode ARIMA (2,1,1). Terlihat nilai aktualnya berturut-turut adalah 82, 88, 86, 90, 89. Sementara itu pada nilai *forecasting* didapat hasil berturut-turut yakni 84.679, 88.791, 91.329, 92.905, dan 93.920..

**Tabel 6** Hasil Test Akurasi Nilai Aktual dan Nilai Hasil  
Forecast Dari Data Testing Menggunakan ARMA (2,1)

ME	RMSE	MAE	MAPE
9.849	11.444	9.849	10.214

Hasil evaluasi akurasi menggunakan model ARMA(2,1) menunjukkan bahwa model memiliki performa prediksi yang cukup baik, meskipun terdapat deviasi kecil antara nilai aktual dan nilai forecast. Nilai *Mean Error* (ME) dan *Mean Absolute Error* (MAE) sebesar 9.849 mengindikasikan rata-rata error model berada di kisaran yang relatif kecil. *Root Mean Squared Error* (RMSE) sebesar 11.444 menunjukkan adanya beberapa error lebih besar

yang mempengaruhi hasil, tetapi tetap terkendali. Sementara itu, *Mean Absolute Percentage Error* (MAPE) sebesar 10.214% menunjukkan bahwa error model berada dalam rentang yang cukup baik, dengan kesalahan prediksi rata-rata sekitar 10% dari nilai aktual. Secara keseluruhan, model ini cukup andal untuk memprediksi data dengan pola yang sederhana.

## Kesimpulan

Penelitian ini menggunakan model deret waktu stasioner untuk menganalisis data cuaca harian di Central Park, New York, pada tahun 2016. Untuk memastikan data stasioner, maka dilakukan uji Augmented Dickey-Fuller (ADF) dengan hasil bahwa setelah satu kali differencing, data tersebut menjadi stasioner. Model ARMA (1,2) dipilih sebagai model terbaik karena memiliki nilai AIC dan BIC terendah dibandingkan model lain. Model ini mampu menangkap pola musiman suhu harian dengan baik, seperti peningkatan suhu selama musim panas dan penurunan suhu di musim dingin, serta menghasilkan prediksi yang akurat terhadap variabilitas suhu harian. Model ini memberikan manfaat dalam memahami fluktuasi suhu di wilayah perkotaan, yang dapat digunakan untuk perencanaan infrastruktur dan manajemen risiko akibat cuaca ekstrem.

## References

- [1] B. K. Sovacool, "The avian benefits of wind energy: A 2009 update," *Renew Energy*, vol. 49, pp. 19–24, Jan. 2013, doi: 10.1016/j.renene.2012.01.074.
- [2] Y. Lai and D. A. Dzombak, "Use of the Autoregressive Integrated Moving Average (ARIMA) Model to Forecast Near-Term Regional Temperature and Precipitation," *Weather Forecast*, vol. 35, no. 3, pp. 959–976, Jun. 2020, doi: 10.1175/WAF-D-19-0158.1.
- [3] M. Eliades, A. Bruggeman, H. Djuma, C. Christofi, and C. Kuells, "Quantifying Evapotranspiration and Drainage Losses in a Semi-Arid Nectarine (*Prunus persica* var. *nucipersica*) Field with a Dynamic Crop Coefficient (Kc) Derived from Leaf Area Index Measurements," *Water (Basel)*, vol. 14, no. 5, p. 734, Feb. 2022, doi: 10.3390/w14050734.